

UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

Facultad de Computación

Planificación y Toma de Decisiones en IA (CS5363)

Vitrina IA: Probador Virtual de Estilos de Vestimenta para Tiendas de Moda en Línea

Sistema generativo interactivo con feedback humano y explicación mediante agentes de IA

Proyecto 2 – Informe final: sistema implementado, resultados y limitaciones

Integrantes

Edgar Moisés Chambilla Mamani
Jose Joaquin Osnayo Matos
Luis Anthony Romero Padilla
Andrés Martín Benjamín Torres Ramos
Jose Francisco Wong Orrillo

Profesores

Dra. Aurea Soriano-Vargas
Mg. Robert Buleje-Del-Carpio

Lima, Perú – Noviembre de 2026

1. Definición del problema

Contexto y problema. Comprar ropa por internet obliga a decidir sin probarse la prenda: el cliente la ve sobre un modelo con otro cuerpo, otro tono de piel y otra pose, y debe imaginar cómo le quedaría. Esa incertidumbre frena la compra y termina en devoluciones. ¿Cómo puede una tienda mostrar a cada cliente **cómo se vería él mismo** con distintas prendas, a partir de una sola fotografía, sin alterar su identidad y dejando la decisión en sus manos? Lo planteamos como **toma de decisiones asistida**: la IA propone exactamente cinco looks sobre la foto del cliente; él acepta o rechaza cada uno; el sistema registra las decisiones y vuelve a generar solo los rechazados; y un agente basado en un modelo de lenguaje (LLM) resume qué se aceptó y qué se rechazó, sin contradecir el registro.

Caso de uso. Ana tiene una reunión de trabajo. En la web de la tienda sube una foto suya de cuerpo entero, elige la línea *Mujer*, la ocasión *Reunión* y cómo generar. Recibe cinco looks (por ejemplo, traje sastre beige, blusa blanca con pantalón gris, camisa celeste con jean), rechaza dos y pide una nueva ronda solo para esos. Al final guarda los looks aceptados y recibe un resumen de sus preferencias.

2. Propuesta de valor del producto

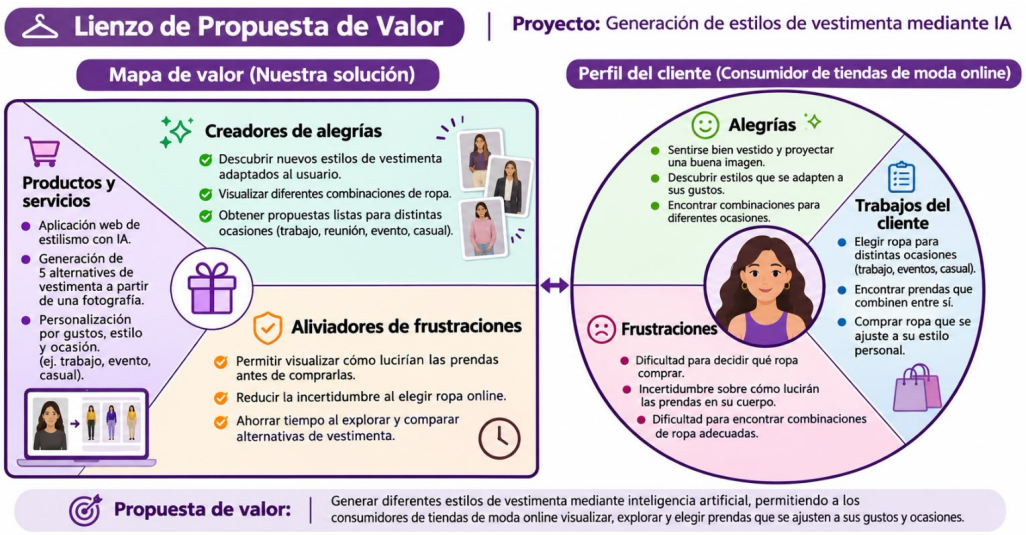


Figura 1: Lienzo de propuesta de valor: perfil del consumidor de tiendas de moda en línea y mapa de valor.

Tabla 1: Las tres preguntas del producto.

¿Qué es?	Un probador virtual web con IA que, a partir de una foto del cliente, genera cinco looks según la ocasión, las prendas del catálogo o una instrucción propia, con dos maneras de generar a elegir (una local y gratuita, y otra por API de pago), revisión por imagen o por paquete, historial restaurable y un resumen explicado y verificado.
¿Para quién es?	Usuario final: consumidores de tiendas de moda en línea. Cliente que paga: las tiendas, que integran el probador en su web (modelo B2B2C).
¿Para qué sirve?	Para que el consumidor compre con más confianza y descubra combinaciones por ocasión (trabajo, reunión, evento, casual), y para que la tienda conozca sus preferencias a partir de un registro explícito de aceptadas y rechazadas.

Design thinking. Empatizar, definir el punto de vista *"necesito saber cómo me queda una prenda y con qué combinarla antes de pagar"*, idear, prototipar y testear. Las entrevistas con compradores y las pruebas con participantes **aún no se realizaron**; no reportamos cifras de mercado ni de ventas, y los supuestos de negocio se marcan como tales (Sección 9).

3. Objetivos y requisitos

Objetivo general. Desarrollar un probador virtual generativo que muestre al cliente cinco looks sobre su propia foto, controlados por sus decisiones y explicados por un agente LLM fiel a ellas. La Tabla 2 resume el estado de cada objetivo específico.

Tabla 2: Objetivos específicos (un verbo cada uno) y su estado al cierre.

OE	Objetivo	Estado y evidencia
OE1	Diseñar la arquitectura y la experiencia de usuario	Cumplido: Sección 5 y interfaz propia
OE2	Preparar las fotos y el catálogo para la generación	Parcial: fotos de prueba y catálogo curado; sin dataset propio con consentimiento
OE3	Implementar dos maneras de generar cinco looks por foto	Cumplido: intermedio local y básico por API (Sección 6)
OE4	Desarrollar una interfaz que registre decisiones e itere	Cumplido: nueva ronda, historial y restauración
OE5	Integrar un agente LLM verificado contra el registro	Cumplido con 2 LLM y verificador determinista
OE6	Incorporar guardrails de entrada y de salida	Cumplido (Sección 8)
OE7	Evaluar con métricas de generación, explicabilidad, uso y negocio	Parcial: sin pruebas con participantes (Sección 9)

Tabla 3: Requisitos funcionales (RF) y restricciones (R).

Requisitos funcionales		Restricciones	
RF1	Cargar y validar una foto del cliente.	R1	Equipo local: GPU de 4 GB y 15,7 GB de RAM; Colab y Kaggle gratuitos con cuota limitada.
RF2	Elegir la manera de generar y una ocasión, prendas o una instrucción.	R2	Gratuito por defecto: la API es opcional, de pago y con consentimiento.
RF3	Generar exactamente cinco looks (V1–V5).	R3	Solo modelos con licencia compatible con el uso.
RF4	Aceptar o rechazar cada look, o el paquete.	R4	Solo fotos con consentimiento; no se publican fotos de terceros.
RF5	Regenerar solo los rechazados.	R5	Plazo del curso y equipo de cinco personas.
RF6	Guardar historial y restaurar una ronda.	R6	Video $\leq$ 3 min y demo en vivo $\leq$ 6 min.
RF7	Resumir con uno de dos LLM y verificar.	R7	Informe de 10 páginas como máximo.
RF8	Guardar los looks aceptados y ver métricas.		

4. Vigilancia tecnológica y selección de modelos

Revisamos modelos abiertos en Hugging Face y servicios comerciales. La Tabla 4 indica qué usamos, qué probamos y qué dejamos como trabajo futuro; las licencias son las declaradas en cada ficha y no constituyen una verificación legal.

Tabla 4: Modelos evaluados y su estado.

Modelo	Estado	Rol y licencia
SD 1.5 Inpainting	Usado	Regenera solo la zona de la ropa (intermedio); CreativeML OpenRAIL-M
ControlNet 1.1 OpenPose	Usado	Mantiene la pose del cliente; OpenRAIL
SegFormer B2 (ATR)	Usado	Máscaras de ropa, rostro y cabello; licencia por verificar
ViTPose base	Usado	Ubica muñecas y manos; Apache-2.0
CLIP ViT-B/32	Usado	Elige entre candidatos y mide ΔCLIP; MIT (código)
gpt-image-2 (OpenAI, API)	Usado	Básico por API; de pago, términos del servicio
SD 1.5 + LoRA propio	Entrenado, no adoptado	Experimento del nivel avanzado (Sección 7)
Qwen2.5-1.5B, Phi-3.5-mini	Usados	Los dos LLM que explican; Apache-2.0 y MIT
IP-Adapter, IDM-VTON	No probados	Prenda exacta a partir de su foto; trabajo futuro

Decisión. Elegimos dos de los tres niveles del enunciado. El **básico** usa un servicio comercial (API de imágenes), que es la forma más fiel en colores pero de pago, sin semilla fija y con la foto fuera del equipo. El **intermedio** corre en local, es gratuito y reproducible, y conserva el rostro por construcción porque solo regenera la ropa. El cliente elige cuál usar y, si uno falla, queda el otro. Exploramos además el **avanzado** (un LoRA propio), que no se adoptó. Las prendas son *descripciones* y no artículos concretos: reproducir una prenda exacta exige que la tienda aporte sus fotos (Sección 10).

5. Diseño del sistema

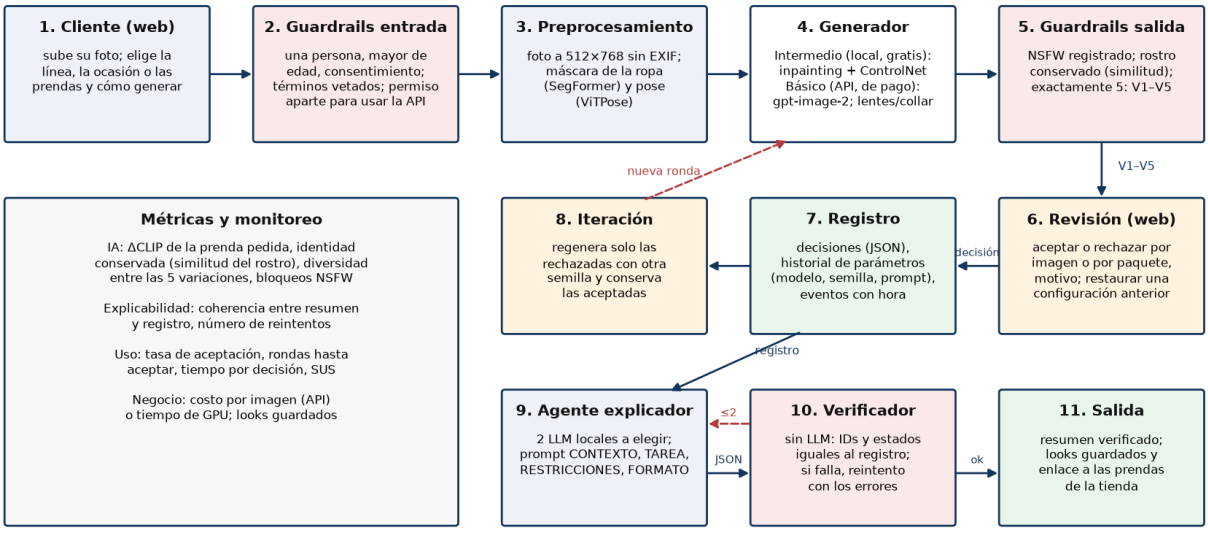


Figura 2: Arquitectura y flujo de información y decisiones. Las flechas rojas discontinuas son ciclos de corrección: nueva ronda sobre los looks rechazados y reintento del LLM con los errores del verificador.

La aplicación es una sola interfaz web (Gradio) que se ejecuta en la laptop del equipo, sin notebook; el mismo código corre en Colab o Kaggle como respaldo. **Ocasiones y catálogo.** Cuatro ocasiones

(*Trabajo*, *Reunión*, *Evento* y *Casual*) y dos líneas (mujer y hombre) definen listas de looks; los looks de hombre son conjuntos completos con pantalón y solo *Casual* admite short. **Semillas e historial.** En modo prueba la semilla es fija (1001 más 100 por ronda más la posición del look), de modo que la misma entrada reproduce las mismas imágenes; en producción se sortea. Cada ronda guarda en el historial el enfoque, el modelo, las semillas y los textos, y permite restaurarla. **Explicación.** El agente recibe el registro, redacta el resumen y un verificador determinista compara identificadores y estados; si falla reintenta hasta dos veces; si sigue fallando, el programa fija el estado de cada look y el LLM solo reescribe el motivo (las listas de aceptadas y rechazadas salen siempre del registro) y, como último recurso, usa una plantilla marcada como tal.

6. Implementación

6.1. Intermedio: inpainting local de la ropa

SegFormer segmenta ropa, piel, rostro y cabello, y ViTPose ubica las muñecas. La máscara cubre la prenda y, si es de manga larga, también los brazos; **las manos se protegen** (círculo más allá de la muñeca, solo píxeles de piel) y del cabello solo se protege el núcleo para que la tela pase bajo el borde. La zona se amplía a 640 px, se regenera con SD 1.5 Inpainting y ControlNet de pose (20 pasos, Euler) y se pega de vuelta; se generan dos candidatos por look y CLIP elige el más cercano al texto, penalizando los estampados que el modelo inventa. Cada descripción lleva un solo color por prenda. Después se limpia el fondo junto a la silueta. Los **accesorios** (lentes y collar) se pintan en una segunda pasada sobre una zona pequeña ubicada con la pose; el collar solo se dibuja sobre piel visible.

6.2. Básico: API de imágenes

El enfoque envía la foto a la API de OpenAI (`gpt-image-2`) con la descripción del look y la instrucción de conservar rostro, manos, zapatos, pose y fondo; los accesorios van en la misma llamada. Tras recibir la imagen se devuelven el rostro y el núcleo del cabello de la foto original. Exige una casilla de consentimiento aparte, registra las imágenes y el costo estimado, y no admite semilla fija.

6.3. Catálogo curado con modelos reales

El catálogo final tiene 33 prendas (8 de mujer y 25 de hombre) y 8 accesorios. Cada prenda se probó con los modelos reales sobre fotos de prueba; **retiramos alrededor de 25** por fallas repetidas (colores mezclados, mangas o manos defectuosas) y descartamos el calzado y los aretes porque salían deformados. Con pantalón en la foto no se ofrecen vestidos ni shorts, porque el modelo no logra dibujar las piernas.

6.4. Interfaz

La identidad visual es **la cinta métrica**: una cinta amarilla con las marcas 1 a 5 recorre la cabecera y cada look cuelga de su propio tramo, que se marca al decidir («Aceptado» o «Descartado», con la foto atenuada y tachada). Las dos maneras de generar se ven siempre; el modelo que explica y el modo prueba quedan en ajustes avanzados. La Figura 3 muestra el estado inicial. Una revisión heurística con la lista de Nielsen (autoevaluación asistida por IA) dio 24/40 antes de corregir los cuatro problemas mayores; no sustituye las pruebas con usuarios.

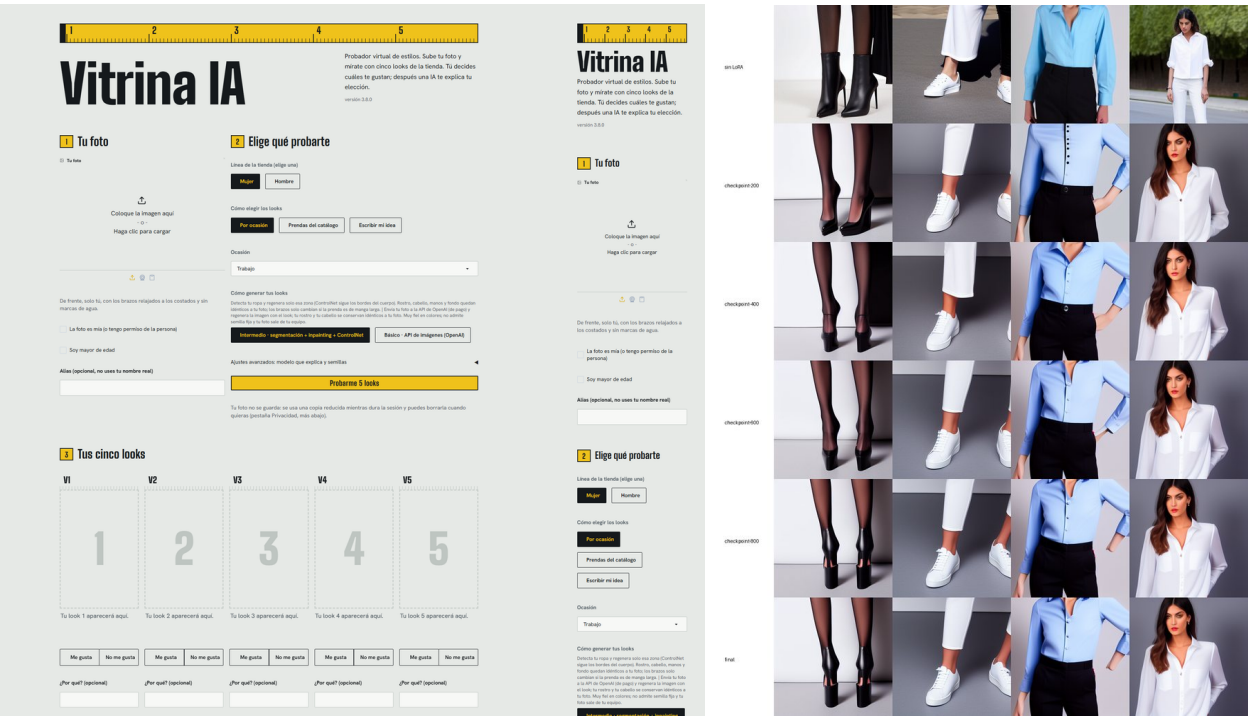


Figura 3: Izquierda: interfaz en escritorio y móvil (estado inicial; el recuadro «Aceptado/Descartado» aparece al decidir). Derecha: comparación del LoRA (Sección 7); filas: sin LoRA y puntos de control a los 200, 400, 600 y 800 pasos y el final; columnas: tacones, zapatillas, camisa celeste y blusa blanca. Todas las personas son sintéticas.

7. Nivel avanzado: un LoRA propio como experimento

Qué se hizo. Por indicación de la profesora, entrenamos un LoRA [6] sobre SD 1.5 para que el probador reprodujera mejor prendas concretas. Los datos son un **catálogo sintético** generado con SD 1.5 (los datasets abiertos de ropa tienen fotos sueltas y desordenadas, poco parecidas a un catálogo): 29 prendas definidas y, en el piloto, cuatro (tacones negros, zapatillas blancas, camisa celeste y blusa blanca) con 120 imágenes, de las que **curamos 76**. En la primera tanda detectamos que el color se contaminaba (una blusa «blanca» con pantalón gris salía gris) y que el calzado salía en poses imposibles, por lo que corregimos los textos y añadimos fotos de producto del calzado. El entrenamiento corrió en Colab (T4): solo el UNet, rango 16, 800 pasos, tasa 1e-4, guardando cada 200 pasos; el archivo pesa 12,8 MB.

Resultados. (i) A partir de los 400 pasos el calzado se deforma (tacones con bloques y agujeros) y a los 800 aparecen artefactos en las camisas: el sobreajuste con 76 imágenes es real; el mejor punto fue el de 200. (ii) Aparece una **fuga de identidad**: todas las blusas muestran la misma mujer del entrenamiento. (iii) Aplicado al probador (por inpainting, misma foto y mismas semillas, cinco looks), el LoRA solo mejoró uno y empeoró o igualó el resto (camisas más saturadas, un jean que salió blanco), por lo que **no se adoptó**. El análisis pedido para este nivel (retos de entrenamiento, control y estabilidad) queda documentado con estos resultados; el hardware de la universidad (A100 y A6000 por fracciones) sí alcanzaría, pero su cola de trabajos largos no era confiable para el plazo.

8. Guardrails y consideraciones éticas

Tabla 5: Guardrails implementados y riesgo que mitigan.

Guardrail	**Funcionamiento**	**Riesgo**
Consentimiento y edad	Declaración de que la foto es suya y de que es mayor de edad; máximo una persona	Fotos de terceros o menores
Consentimiento de la API	Casilla aparte antes de enviar la foto a OpenAI; sin ella no se envía nada	Foto fuera del equipo
Prendas y términos	Lista cerrada de prendas y términos vetados (también en la traducción)	Sexualización, marcas
Cuerpo y rostro	La máscara cubre solo la ropa; se compara el rostro con el original (umbral 0,45)	Cambios de identidad
Filtro NSFW	Safety checker sobre cada imagen generada; solo se registra (ver abajo)	Contenido sexual
Privacidad	No se guarda la foto; copia reducida solo durante la sesión; botón para borrarla	Datos biométricos
Etiquetado y verificador	Etiqueta «Simulación IA»; verificación del resumen con plantilla de respaldo	Engaño, alucinación

Reflexión. El mayor riesgo es la **sexualización y los *deepfakes***: un sistema que «cambia la ropa» puede usarse para desvestir. Lo mitigamos de forma preventiva (lista cerrada, máscara limitada a la ropa, términos vetados) y no solo con un filtro posterior. De hecho, el filtro NSFW de SD dio **falsos positivos con ropa normal** (suéteres, blazers) y nos hizo mostrar imágenes negras; por eso decidimos **registrarlo y no bloquear**, a costa de depender de la prevención. También hay **sesgos**: los modelos de difusión representan mejor ciertos cuerpos y tonos, y los datos sintéticos heredan los sesgos del generador (la fuga de identidad del LoRA lo ilustra). Con la API la foto sale del equipo, de ahí el consentimiento aparte. Por último, la foto es un dato personal (Ley N.º 29733) y la simulación debe presentarse como tal (Ley N.º 29571). **No se publican fotos de terceros** en este repositorio.

9. Evaluación

Tabla 6: Resultados medidos. Las muestras son pequeñas (una foto de prueba y cinco looks por conjunto): son exploratorios.

Dimensión	Resultado	Límite
Cinco looks por solicitud	Siempre 5; comprobado por las pruebas automáticas	Con modelos simulados
Coherencia del resumen	Un verificador sin LLM comprueba cada resumen; en el piloto previo el LLM acertó solo en 3 de 4 sesiones y ningún resumen incoherente llegó al usuario	Pruebas y piloto previo
Colores correctos	API: 5 de 5 looks; intermedio: 3 de 5 (pantalón «negro» azul, blusa «blanca» negra)	Una foto, revisión visual
Identidad	Intermedio: rostro fuera de la máscara. API: SSIM de la caja del rostro de 0,74 a 0,80 tras restaurar rostro y cabello	La caja incluye cuello y cuello de la prenda
Tiempo por 5 looks	API: unos 130 s; intermedio: de 2 a 5 min en la GPU de 4 GB (de 40 a 60 s en versiones sin accesorios)	Depende de la memoria libre
Costo	API: unos \$0,023 por imagen (el saldo bajó de \$10,00 a \$9,86 tras 6 imágenes), unos \$0,12 por prueba; local: \$0	Estimado y redondeado
Avanzado (LoRA)	Sin mejora neta; sobreajuste desde los 400 pasos; fuga de identidad	Un piloto de 4 prendas
Usabilidad (SUS)	Cuestionario implementado en la app; **sin participantes aún**	Pendiente

Viabilidad y negocio. El costo variable de la API es de centavos por prueba, y el del enfoque local es cero pero más lento y limitado por la memoria. El modelo B2B2C propuesto (la tienda paga por pruebas) y su precio, el efecto sobre ventas o devoluciones y la disposición a pagar son **supuestos a validar**, no resultados.

10. Limitaciones y trabajo pendiente

- **Colores mezclados en el intermedio.** Con dos prendas de distinto color en una frase, SD 1.5 las mezcla o las intercambia. La solución pensada es pintar arriba y abajo en dos pasadas con una prenda cada una; no está aplicada.
- **Prendas descritas, no exactas.** Para reproducir un artículo concreto la tienda debe aportar fotos de sus prendas y usar un método con imagen de referencia (IP-Adapter u otro), que no probamos.
- **Falta de pruebas con usuarios.** No hay aún cuestionario SUS con participantes ni el video con un participante externo; ambos son parte de la entrega.
- **Poses y fotos difíciles.** Manos sobre el cuello o ropa muy holgada fallan; pedimos foto frontal con brazos relajados. El calzado y los aretes quedaron fuera por no salir bien.
- **Memoria.** En la laptop de 4 GB, el intermedio compite por la memoria con otros programas.

Tabla 7: Cumplimiento de los requisitos del enunciado.

Requisito	Estado	Evidencia o pendiente
Exactamente cinco variaciones por foto	Cumplido	Pruebas automáticas y sesiones reales
Interfaz para aceptar o rechazar cada una	Cumplido	Por imagen o por paquete, con motivo opcional
Decisiones registradas de forma estructurada	Cumplido	Registro de decisiones, eventos e historial
Agente LLM coherente con el registro	Cumplido	Dos LLM y verificador determinista
Dos de tres niveles de implementación	Cumplido	Básico (API) e intermedio; avanzado explorado
Guardrails; semilla fija y variable; historial	Cumplido	Sección 8 y Sección 5
Vigilancia tecnológica de modelos	Cumplido	Tabla 4
Dataset justificado y análisis exploratorio	Parcial	Fotos de prueba y catálogo curado; sin dataset propio
Métricas de calidad, diversidad, coherencia y usabilidad	Parcial	Falta el SUS con participantes
Reflexión ética	Cumplido	Sección 8
Video (3 min) con un participante externo	Pendiente	Guion listo; falta grabarlo
Demostración en vivo (6 min)	Pendiente	Guion listo
Informe de 10 páginas como máximo	Cumplido	9 páginas, compilado con pdfLaTeX

Referencias

[1] R. Rombach et al., "High-Resolution Image Synthesis with Latent Diffusion Models", CVPR, 2022.

[2] L. Zhang, A. Rao y M. Agrawala, "Adding Conditional Control to Text-to-Image Diffusion Models", ICCV, 2023.

[3] Z. Cao et al., "OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields", IEEE TPAMI, 2021.

[4] E. Xie et al., "SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers", NeurIPS, 2021.

[5] Y. Xu et al., "ViTPose: Simple Vision Transformer Baselines for Human Pose Estimation", NeurIPS, 2022.

[6] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models", ICLR, 2022 (arXiv:2106.09685).

[7] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision", ICML, 2021.

[8] Qwen Team, "Qwen2.5 Technical Report", arXiv:2412.15115, 2024.

[9] M. Abdin et al., "Phi-3 Technical Report", arXiv:2404.14219, 2024.

[10] H. Ye et al., "IP-Adapter: Text Compatible Image Prompt Adapter for Text-to-Image Diffusion Models", arXiv:2308.06721, 2023.

[11] Y. Choi et al., "Improving Diffusion Models for Authentic Virtual Try-on in the Wild" (IDM-VTON), ECCV, 2024.

[12] J. Brooke, "SUS: A Quick and Dirty Usability Scale", en *Usability Evaluation in Industry*, 1996.

[13] J. Nielsen, "10 Usability Heuristics for User Interface Design", Nielsen Norman Group, 1994.

[14] Congreso de la República del Perú, Ley N.º 29733, Ley de Protección de Datos Personales, 2011.

[15] Congreso de la República del Perú, Ley N.º 29571, Código de Protección y Defensa del Consumidor, 2010.